AML — White-Box Konzeptübersicht

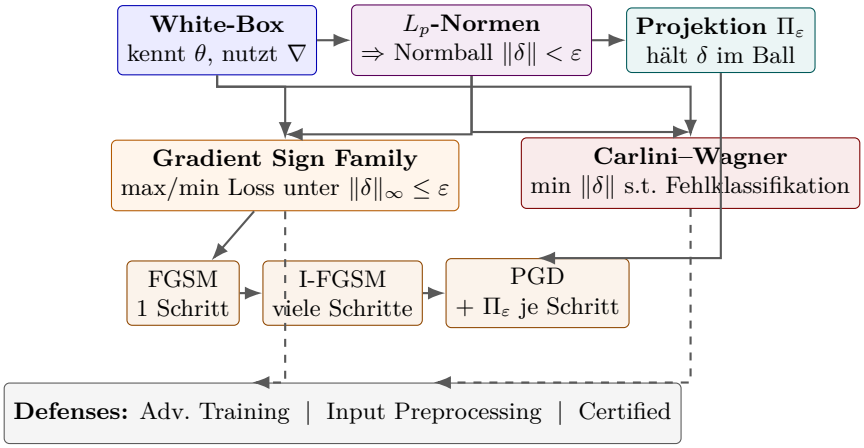
Vorlesung *Adversarial Machine Learning* (Rieck) + Papers

Extrem kompakte Landkarte: Begriffe, Formeln, Verbindungen

Ziel dieses Dokuments

Alles Wichtige aus den Slides `aml-advwhite-small` an einem Ort — **was** die Konzepte sind und **wie** sie zusammenhängen. Papers (Goodfellow, Carlini&Wagner) nur als Brücke, wo sie die Slides vertiefen.

1 Landkarte: Wie hängt alles zusammen?



Eine Zeile Zusammenfassung

Normen sagen, was "klein" heiSSt. **GSM/PGD** schieben entlang des Loss-Gradienten im ε-Ball. **C&W** sucht die *kleinste* Störung, die die Klasse kippt.

2 Notation (einmal, dann überall gleich)

Symbol	Bedeutung
$x \in \mathbb{R}^d$	Original-Eingabe (z. B. Bild in $[0,1]^d$)
y	wahres Label (Ground Truth)
$t \neq y$	Zielklasse (nur bei targeted)
f / θ	Modell / Parameter (White-Box: beides bekannt)
$z(x)$	**Logits** (Ausgabe *vor* Softmax)
δ	Störung; $\bar{x} = x + \delta$ = adversariales Beispiel
ε	Budget: erlaubt ist nur $\|\delta\| < \varepsilon$ (Normball)
ℓ	Loss (z. B. Cross-Entropy)

3 Teil 1 — Vektornormen, Normball, Projektion

3.1 Vier Normen — was sie messen

Norm $\|\cdot\|$ misst die "GröSSe" der Störung δ. In AML proxy für *menschliche Unauffälligkeit*.

Norm	Formel	Intuition für Angriffe
L_0	Anzahl Nicht-Nullen	wenige Pixel stark ändern
L_1	$\sum_i \lvert\delta_i\rvert$	Manhattan / Summe der Beträge
L_2	$\sqrt{\sum_i \delta_i^2}$	viele Pixel etwas ("Energie")
L_∞	$\max_i \lvert\delta_i\rvert$	kein Pixel mehr als ε

Beispiel $x = (0, 3, 4)$: $\|x\|_0 = 2$, $\|x\|_1 = 7$, $\|x\|_2 = 5$, $\|x\|_\infty = 4$.

3.2 Normball

$$\{\bar{x} : \|\bar{x} - x\| < \varepsilon\} \quad = \quad \{x + \delta : \|\delta\| < \varepsilon\}$$

Alles Erlaubte liegt *innerhalb* dieses Balls um x.

3.3 Projektion Π_ε

Mappt einen Vektor zurück *auf/in* den Normball:

$$\Pi_\varepsilon(v) = \begin{cases} v & \text{falls } \|v\|_p < \varepsilon, \\ s(v) & \text{sonst.} \end{cases}$$

- L_2: Skalierung $s(v) = v \cdot \varepsilon / \|v\|_2$
- L_∞: Clamping $s(v) = \min(\max(v, -\varepsilon), \varepsilon)$

Verbindung zu Angriffen

FGSM nutzt die Form des L_∞-Balls direkt ($\delta = \varepsilon \cdot \text{sign}(g)$).
PGD braucht Π_ε nach jedem Schritt.
C&W *minimiert* die Norm statt ein festes ε vorzugeben.

4 Teil 2 — Was ist ein White-Box Adversarial Example?

Ziel (Integrity): Vorhersage f bei Inferenz täuschen.
Finde kleines δ mit

$$f(x + \delta) \neq y \qquad \text{und} \qquad \|\delta\| < \varepsilon.$$

White-Box = Angreifer kennt Architektur und Parameter θ und darf Gradienten ∇_x / ∇_δ berechnen.

Problem-Space vs. Feature-Space

Feature-Space: Störung direkt auf dem Modellinput (Pixel, Embeddings).
Problem-Space: Störung muss in der realen Welt gültig bleiben (Foto, Audio, ...). Die Vorlesung startet im Feature-Space.

5 Teil 3 — Gradient Sign Methods

Idee: Die Störung folgt dem **Gradienten des Loss** — der Richtung, in der die Vorhersage am schnellsten schlechter (oder zur Zielklasse besser) wird.

5.1 Zwei Angriffsziele

Untargeted	$\arg\max_{\delta} \ell(f(x+\delta), y) \quad \text{s.t. } \|\delta\| < \varepsilon$	(Loss der *wahren* Klasse hoch)
Targeted	$\arg\min_{\delta} \ell(f(x+\delta), t) \quad \text{s.t. } \|\delta\| < \varepsilon,\ t \neq y$	(Loss der *Zielklasse* runter)

5.2 FGSM — ein Schritt

Gradient $g = \nabla_\delta \ell(f(x+\delta), y)$. Skaliertes g rutscht leicht aus dem Ball; bei groSSem α clampen alle Koordinaten auf $\pm\varepsilon$. Deshalb der Sign-Trick:

$$\boxed{\delta \;=\; \varepsilon \cdot \operatorname{sign}(g)} \qquad \text{(klassisch: } \bar{x} = x + \varepsilon \cdot \operatorname{sign}(\nabla_x J(\theta, x, y))\text{)}$$

$\Rightarrow$ natürlich an L_∞ gekoppelt, extrem schnell, oft schwach.

5.3 I-FGSM — viele kleine Schritte

$$\delta_k \;=\; \delta_{k-1} + \alpha \cdot \operatorname{sign}(g_{k-1})$$

Neue Hyperparameter: Schrittweite α, Iterationen k. Früh abbrechen, sobald die Entscheidungsgrenze überschritten ist. **Problem:** δ kann den Normball verlassen.

5.4 PGD — I-FGSM + Projektion

$$\boxed{\delta_k \;=\; \Pi_\varepsilon\big(\delta_{k-1} + \alpha \cdot \operatorname{sign}(g_{k-1})\big)}$$

Kette merken

FGSM = 1Œ Gradient-Sign $\rightarrow$ **I-FGSM** = FGSM iteriert $\rightarrow$ **PGD** = I-FGSM + Π_ε nach jedem Schritt.
PGD gilt als Standard-**starke** L_∞-Baseline zur Defense-Evaluation.

6 Teil 4 — Carlini–Wagner (andere Philosophie)

6.1 Ausgangsproblem

Statt Loss zu maximieren: **Norm minimieren**, Klasse erzwingen:

$$\arg\min_{\delta} \ \|\delta\| \quad \text{s.t.} \quad f(x+\delta) = t, \quad x + \delta \in [0,1]^d.$$

Zwei harte Punkte: (1) diskrete Klassenbedingung, (2) Box $[0,1]^d$.

6.2 Trick 1 — weiche Nebenbedingung A

Ersetze $f(\bar{x}) = t$ durch $A(\bar{x}) \leq 0 \ \Leftrightarrow$ Angriff erfolgreich:

$$\arg\min_{\delta} \ \|\delta\| + c \cdot A(\bar{x}) \quad \text{s.t.} \quad \bar{x} \in [0,1]^d.$$

$c > 0$ steuert Tradeoff Distanz vs. Erfolg (oft Binary Search).

Empirisch starke Wahl auf **Logits** z (nicht Softmax):

$$A(\bar{x}) = \max\Big(0,\ \max_{i \neq t} z(\bar{x})_i - z(\bar{x})_t\Big)$$

z_t soll gröSSer sein als alle anderen Logits. Softmax-Objectives können numerisch "sterben" (Gradient ≈ 0).

6.3 Trick 2 — Box weg via tanh

$$\delta \;=\; \tfrac{1}{2}\big(\tanh(w)+1\big) - x \quad \Rightarrow \quad \bar{x} = \tfrac{1}{2}(\tanh(w)+1) \in (0,1)^d.$$

Optimierung ist dann **unbeschränkt** über w (z. B. Adam).

6.4 C&W-L_2 (Kernformel der Vorlesung)

$$\arg\min_w \ \Big\|\tfrac{1}{2}(\tanh(w)+1) - x\Big\|_2^2 \ + \ c \cdot A\Big(\tfrac{1}{2}(\tanh(w)+1)\Big)$$

L_0/L_∞-Varianten: andere äuSSere Schleifen (Pixel fixieren bzw. τ-Schwellwert); Innen oft wieder L_2-artige Optimierung — Details im Paper.

GSM vs. C&W

GSM/PGD: festes Budget ε, Loss pushen.
C&W: kleinstmögliche Distanz suchen, Erfolg über $A \leq 0$ erzwingen.
Beide sind White-Box und gradientenbasiert — unterschiedliche Zielfunktion.

7 Vergleichstabelle aller Angriffe

	FGSM	**I-FGSM**	**PGD**	**C&W**
Idee	1 Sign-Schritt	viele Schritte	+ Projektion	min Norm + A
Typ. Norm	L_∞	L_∞	L_∞	L_0, L_2, L_∞
Budget	fest ε	fest ε	fest ε	sucht kleines $\|\delta\|$
Geschwindigkeit	sehr schnell	mittel	mittel	langsam
Stärke	schwach	stärker	stark	sehr stark
Braucht Π_ε?	implizit	oft ja	**ja**	nein (tanh)

Historische Brücke (Papers, nicht Schwerpunkt der Slides): **L-BFGS** (Szegedy) = frühe Optimierung $\min c\|x' - x\|_2^2 + \text{loss}$ — stark aber teuer; motivierte FGSM (schnell) und später C&W (besseres f/Logits).

8 Defenses (nur Überblick aus den Slides)

Keine allgemein starke Defense — aktives Forschungsfeld:

1. **Adversarial Training:** mit Adv. Examples nachtrainieren (oft FGSM/PGD on-the-fly). Robustheit gilt nur gegen die genutzte Attack-Stärke.
2. **Input Preprocessing:** Transformationen, die Störungen abschwächen.
3. **Certified Defenses:** Garantien innerhalb eines Normballs.

Evaluation-Regel

Eine Defense nur gegen FGSM testen reicht nicht. Starke Angriffe (PGD, C&W) sind der MaSSstab — Kernbotschaft von Carlini&Wagner.

9 Begriffs-Netz (Schnelllookup)

Begriff	Hängt zusammen mit ...
White-Box	θ bekannt $\Rightarrow$ Gradienten $\Rightarrow$ GSM & C&W möglich
L_p**-Norm**	definiert "klein"; wählt Normball-Form
Normball / ε	erlaubte Störungen; Constraint bei GSM/PGD
Projektion Π_ε	hält Iterationen im Ball; Kern von PGD
sign(g)	optimale L_∞-Richtung bei linearem Loss-Zuwachs
FGSM $\rightarrow$ **I-FGSM** $\rightarrow$ **PGD**	Verfeinerung derselben Idee
Logits z	stabiles C&W-Objective A; Softmax oft fragil
$A(\bar{x}) \leq 0$	weiche Erfolgsbedingung statt $f(\bar{x}) = t$
tanh**-Trick**	entfernt Box-Constraint $[0,1]^d$
c **(C&W)**	Tradeoff Distanz vs. Angriffserfolg
Adv. Training	Defense; Evaluation braucht starke Attacks

10 Checkliste vor der Prüfung / dem Coding

1. Normball und Π_ε für L_2 und L_∞ erklären können
2. Untargeted vs. targeted Loss hinschreiben
3. FGSM-Formel und warum sign statt skaliertem Gradient
4. I-FGSM vs. PGD in einem Satz unterscheiden
5. C&W: von $\min \|\delta\|$ s.t. $f = t$ zu $\|\delta\| + cA$ + tanh skizzieren
6. Warum C&W auf Logits statt Softmax arbeitet
7. Verbindung: Normen $\leftrightarrow$ Angriffe $\leftrightarrow$ Defenses

Quellen: Vorlesung Rieck, AML Winter 2025/26 (`aml-advwhite-small`); Goodfellow, Shlens & Szegedy (ICLR 2015); Carlini & Wagner (IEEE S&P 2017); Szegedy et al. (ICLR 2014); Xu et al. (2022).